

Reconhecimento de Leitões em Imagens: Metodologia e Desenho experimental

Gustavo E. S. Machado¹

¹Faculdade de Engenharia Elétrica - Universidade Federal de Uberlândia (UFU) -
Uberlândia — MG — Brasil

`gustavo.machado@ufu.br`

Abstract. *This study presents an investigation into piglet recognition in images, including dataset characterization, exploratory analysis, and the adopted methodology. The dataset used contains annotations in YOLO format, organized into training and validation partitions. The statistical analysis indicated a high density of instances per image and low variability in density among the images, as well as relevant factors such as partial occlusion. The study aims to train three different YOLO model versions (V5, V8 and V11) and compare their performance using the selected dataset.*

Resumo. *Este estudo apresenta uma investigação sobre o reconhecimento de leitões em imagens, com caracterização da base de dados, análise exploratória e metodologia adotada. A base utilizada contém anotações no formato YOLO organizada em partições de treino e validação. A análise estatística indicou alta densidade de instâncias por imagem e baixa variabilidade de densidade entre as imagens ou fatores relevantes como oclusão parcial. O estudo tem por objetivo treinar três modelos de diferentes versões do YOLO (V5, V8 e V11) e comparar seu desempenho com o dataset escolhido.*

1. Introdução

A detecção de objetos em imagens e vídeos é um tema central em Visão Computacional, com aplicações em monitoramento inteligente e automação de processos. No domínio de suinocultura de precisão, abordagens recentes baseadas em YOLOv5 têm apresentado resultados promissores para detecção de suínos em ambientes de produção, incluindo variações arquiteturais voltadas à melhoria de robustez e acurácia [Li and Li 2024; Peng et al. 2024]. Neste trabalho, adota-se YOLOv5 como referência técnica de implementação e comparação [Ultralytics 2022].

No domínio de monitoramento animal, a detecção automática de leitões em ambiente coletivo apresenta desafios práticos, como alta concentração de indivíduos por quadro, sobreposição entre os corpos e variações de iluminação. Nesses cenários, a etapa de caracterização dos dados é determinante para o desenho experimental e para a interpretação correta de métricas de desempenho.

Do ponto de vista metodológico, este trabalho adota uma estratégia incremental de investigação, contemplando não apenas o diagnóstico inicial dos dados e a definição

explícita das métricas de avaliação, mas também a descrição da metodologia empregada, as justificativas para as escolhas realizadas, a apresentação dos modelos utilizados e a análise de resultados preliminares obtidos. Nesse contexto, o presente texto consolida a fase inicial da investigação, estabelecendo a questão de pesquisa, caracterizando a base de dados utilizada e apresentando análises exploratórias que servirão como referência para comparações futuras.

2. Análise exploratória da base de dados

Nesta etapa, foi utilizado o conjunto de dados de leitões, obtido no *Kaggle Pig Dataset* [ZIMANGE, s. d.], com anotações no padrão YOLO e organização em partições de treino e validação.

Na caracterização inicial da base adotou-se uma separação de 929 imagens para treino (Figura 1), correspondendo 80% da base de dados, e 136 imagens para validação (Figura 2), representando os 20% restante da base de dados.




Figura 1. Histograma Quantidade leitões por imagem (treinamento)

Complementarmente à contagem de instâncias, foi conduzida uma verificação orientada à consistência espacial das anotações. Para tanto, desenvolveu-se um *script* em Python que lê os arquivos de rótulo no formato YOLO, converte as coordenadas normalizadas para o plano da imagem em pixels e sobrepõe retângulos delimitadores às imagens correspondentes. Esse procedimento viabiliza a inspeção manual de amostras, permitindo detectar desalinhamentos entre rótulo e conteúdo visual, erros de classe ou inconsistências de escala antes de etapas de treinamento e avaliação, Figura 3.




Figura 2. Histograma Quantidade leitões por imagem (validação)




Figura 3. Histograma Quantidade leitões por imagem (validação)

Adicionalmente, analisou-se a distribuição do número de leitões por imagem a partir dos rótulos nas partições de treino e validação (Tabela 1). Percebe-se uma faixa de contagem por quadro com baixa amplitude: para o treino, entre 11 e 15 instâncias por imagem, enquanto na validação a faixa fica entre 12 e 15. E uma massa de distribuição concentrada em $k=13$ e $k=14$, indicando uma alta homogeneidade na carga de objetos por cena.

Tabela 1. Distribuição dos dados de treinamento e validação

Número de leitões (k)	Frequência de treino	Frequência de validação
11	4 (0.43%)	0 (0.0%)
12	22 (2.37%)	8 (5.88%)
13	179 (19.27%)	34 (25.0%)
14	571 (61.46%)	74 (54.41%)
15	153 (16.47%)	20 (14.71%)

3. Metodologia

A metodologia adotada neste trabalho foi estruturada de forma incremental de modo a contemplar a preparação da base de dados, previamente separada, escolha de métrica e treinamento e avaliação comparativa entre diferentes versões da arquitetura YOLO.

Inicialmente, realizou-se a conferência e verificação da consistência da base de dados, incluindo inspeção manual das anotações no formato YOLO e análise da distribuição de instâncias por imagem. Em seguida, foi realizada a separação dos dados em subconjuntos de treinamento e validação, com o objetivo de garantir uma avaliação experimental mais robusta e evitar viés entre as etapas de treinamento e análise final dos modelos.

Posteriormente, foram selecionadas três versões distintas da arquitetura YOLO (YOLOv5, YOLOv8 e YOLOv11), com objetivo de realizar um estudo comparativo de desempenho, robustez e capacidade de generalização no problema de detecção de leitões em ambiente coletivo. De modo a obtermos uma comparação justa entre os modelos, todos os treinamentos foram executados utilizando os mesmos parâmetros experimentais (Tabela 2).

Tabela 2. Detalhamento de parâmetros para treino e validação

Tamanho da imagem em pixels	640px
Épocas de treinamento	100
Batch de imagens	16
Patience	40
Seed	42 (valor randômico fixo)
Limiar de confiança (conf_thres	0,25

Após o treinamento dos modelos os resultados foram avaliados segundo métricas específicas de detecção e tempo de detecção, tornando possível analisar os resultados preliminares para o *dataset* em questão.

4. Métricas de avaliação

A avaliação experimental dos modelos foi conduzida utilizando métricas amplamente empregadas em problemas de detecção de objetos, permitindo analisar tanto a

capacidade de localização dos leitões quanto a confiabilidade das detecções realizadas. Todas as avaliações foram executadas sobre o mesmo conjunto de validação, garantindo condições equivalentes para a comparação entre os modelos YOLOv5, YOLOv8 e YOLOv11.

Foram utilizadas cinco métricas relacionadas à qualidade da detecção e duas métricas voltadas à avaliação do desempenho computacional. Antes de apresentar essas métricas, é necessário definir três conceitos fundamentais dos quais várias delas são derivadas: *True Positive* (TP), *False Positive* (FP) e *False Negative* (FN).

O indicador *True Positive* (TP) ocorre quando o modelo detecta corretamente um leitão presente na imagem. *False Positive* (FP) corresponde a uma detecção incorreta, ou seja, quando o modelo identifica um objeto inexistente ou realiza uma localização inadequada. E por fim, *False Negative* (FN) representa um leitão presente na imagem que não foi detectado pelo modelo. Esses três indicadores constituem a base para o cálculo das principais métricas de desempenho.

As métricas adotadas para avaliar a qualidade da detecção foram *Precision*, *Recall*, *F1-Score*, $\text{mAP}@0.5$ e $\text{mAP}@0.5:0.95$. A métrica *Precision* mede a proporção de detecções corretas entre todas as detecções realizadas pelo modelo, sendo definida por: $P = TP / (TP + FP)$. Valores elevados de *Precision* indicam que o modelo produz poucos falsos positivos. Por sua vez, a métrica *Recall* mede a proporção de objetos corretamente detectados em relação ao total de objetos existentes na imagem, sendo calculada por: $R = TP / (TP + FN)$. Valores elevados de *Recall* indicam que poucos objetos deixaram de ser detectados.

O *F1-Score* corresponde à média harmônica entre *Precision* e *Recall*, permitindo avaliar simultaneamente a capacidade do modelo de detectar objetos corretamente e minimizar erros. Essa métrica é calculada por: $F1 = 2 \times TP / (2 \times TP + FP + FN)$. Quanto mais próximo de 1 for o valor do *F1-Score*, melhor será o equilíbrio entre precisão e cobertura das detecções.

As métricas $\text{mAP}@0.5$ e $\text{mAP}@0.5:0.95$ foram utilizadas como indicadores principais da qualidade da detecção. Ambas consideram a sobreposição entre a caixa delimitadora predita e a anotação real por meio do critério *Intersection over Union* (IoU). Enquanto o $\text{mAP}@0.5$ utiliza um limiar fixo de IoU igual a 0,5, o $\text{mAP}@0.5:0.95$ realiza a média do desempenho em múltiplos limiares de IoU, tornando-se uma métrica mais rigorosa para avaliar a precisão do posicionamento das caixas delimitadoras.

Além das métricas de qualidade, foram avaliadas duas métricas de desempenho computacional: o tempo total de validação e o tempo médio de validação por imagem. Essas métricas permitem analisar a eficiência dos modelos e identificar possíveis trade-offs entre qualidade de detecção e custo computacional, aspecto relevante para aplicações práticas de monitoramento em tempo real.

5. Resultados preliminares

A Tabela 3 apresenta os resultados obtidos pelos três modelos avaliados utilizando o mesmo conjunto de validação. De maneira geral, todos os modelos apresentaram desempenho elevado, com valores de *Precision*, *Recall* e $\text{mAP}@0.50$ superiores a 0,97,

indicando que o problema de detecção foi adequadamente aprendido pelas diferentes arquiteturas.

Tabela 3. Resultado de captura por modelos

Modelo	Experimento	Precision	Recall	mAP@0,50	mAP@0,50:0,95	F1
YOLOv5s	E01	0,9918	0,9776	0,9914	0,8302	0,9846
YOLOv8s	E02	0,9915	0,9803	0,9845	0,7986	0,9858
YOLO11s	E03	0,9865	0,9712	0,9833	0,8025	0,9788

O YOLOv5s (E01) apresentou o melhor resultado em mAP@0,50:0,95 (0,8302), seguido pelo YOLO11s (0,8025) e pelo YOLOv8s (0,7986), indicando melhor qualidade de localização das detecções. Por outro lado, *Precision*, *Recall* e *F1-Score* apresentaram valores elevados e bastante próximos entre os modelos, com destaque para o YOLOv8s, que obteve o maior F1-Score (0,9858).

Quanto ao desempenho computacional, a Tabela 4 ilustra os resultados, os quais observou-se uma diferença significativa entre os modelos. O YOLOv5s apresentou tempo médio de validação de 372,1 ms por imagem, enquanto o YOLOv8s e o YOLO11s registraram 131,9 ms e 123,4 ms por imagem, respectivamente. Dessa forma, os modelos mais recentes mostraram-se aproximadamente três vezes mais rápidos que o YOLOv5s durante a validação.

Tabela 4. Desempenho computacional entre modelos

Modelo	Experimento	Total	ms/img
YOLOv5s	E01	0,9918	0,9776
YOLOv8s	E02	0,9915	0,9803
YOLO11s	E03	0,9865	0,9712

De maneira geral, o YOLOv5s apresentou os melhores resultados em termos de qualidade de detecção, especialmente na métrica mAP@0,50:0,95. Entretanto, o YOLO11s destacou-se por oferecer desempenho próximo ao do YOLOv5s, aliado ao menor tempo de processamento entre os modelos avaliados, configurando uma alternativa interessante quando a eficiência computacional é um fator relevante.

6. Dificuldades e próximos passos

A principal dificuldade identificada neste estudo foi a elevada homogeneidade da base de dados, caracterizada por alta concentração de leitões por imagem e por cenários visualmente muito semelhantes entre si. Essa característica pode ter contribuído para a obtenção de resultados muito próximos entre os modelos avaliados, especialmente nas métricas *Precision*, *Recall* e mAP@0,50. Além disso, a baixa variabilidade das amostras pode indicar uma possível tendência ao *overfitting*, limitando a capacidade de generalização dos modelos para cenários distintos daqueles presentes na base.

Como próximos passos, pretende-se realizar uma análise mais aprofundada da diversidade das imagens e da distribuição dos dados, bem como avaliar estratégias de reorganização das partições de treinamento e validação. Também serão investigadas técnicas de aumento de dados e degradação controlada das imagens, visando aumentar a variabilidade do conjunto de treinamento e permitir uma avaliação mais robusta da capacidade de generalização dos modelos.

References

- L. Li and F. Li, "Pig Detection Method Based on Improved YOLOv5," *2024 International Symposium on Digital Home (ISDH)*, Guilin, China, 2024, pp. 91-96, doi: 10.1109/ISDH64927.2024.00022.
- N. Peng, F. Li and X. Luo, "PLM-YOLOv5: Improved YOLOv5 for Pig Detection in Livestock Monitoring," *2024 International Conference on Intelligent Robotics and Automatic Control (IRAC)*, Guangzhou, China, 2024, pp. 619-625, doi: 10.1109/IRAC63143.2024.10871878.
- ULTRALYTICS. YOLOv5. GitHub, [S. l.], 2022. Disponível em: <https://github.com/ultralytics/yolov5>. Acesso em: 24 abr. 2026.